

Informe de Prueba Técnica

DataKnow

Científico de Datos Junior

Medellin, Colombia

Julio 2026

1. Explicacion del Caso

Una empresa del sector construccion planifica un proyecto con una ventana de ejecucion definida. Historicamente, los costos de adquisicion de dos tipos de equipos criticos (Equipo 1 y Equipo 2) han presentado variaciones que generan desviaciones presupuestales. La gerencia sospecha que estos precios estan relacionados con materias primas del mercado (X, Y, Z), pero no existe un modelo formal que lo confirme.

Se dispone de 3,530 registros diarios de precios (enero 2010 a agosto 2023) que incluyen las materias primas X, Y, Z y los precios de los dos equipos. El objetivo es identificar que materias primas explican el costo de cada equipo, proyectar costos futuros, y construir un agente de IA que permita consultar los resultados. Los datos se resampearon a frecuencia mensual (promedio del mes), obteniendo 164 observaciones.

2. Supuestos

Los supuestos adoptados para el análisis son los siguientes:

1. Relacion lineal. Se asume relacion lineal entre materias primas y equipos ($R^2 > 0.99$).
2. Frecuencia mensual. El caso solicita proyección mensual. Se uso promedio del mes.
3. Multicolinealidad Y-Z no invalida. Correlación 0.84, VIF 3.5. Como el objetivo es predicción y no inferencia causal, la multicolinealidad no afecta los resultados ($R^2 > 0.99$).
4. Caminata aleatoria. ADF: $p > 0.05$ niveles, $p < 0.01$ 1a diferencia.

5. Normalidad residual aproximada. Shapiro $p < 0.01$, QQ-plots razonables. $IC = 1.96 \times \sigma$.

6. 22 días hábiles/mes. Para traducir costo diario a presupuesto mensual.

3. Formas de Resolver y Opcion Tomada

3.1 Alternativas Consideradas

Enfoque	Razon
SMA(3) / SMA(6)	Mayor error que Naive en backtest
SES	Alpha = 1.0 (equivalente Naive)
Naive	Seleccionado: menor error, consistente con caminata aleatoria

Se utilizó regresión lineal múltiple (OLS, Mínimos Cuadrados Ordinarios) como técnica de modelado. Se probaron las 7 combinaciones de variables y se seleccionaron los modelos con mejor R^2 y AIC. Naive se eligió por backtest contra SMA(3), SMA(6) y SES.

4. Resultados del Análisis

4.1 Correlaciones

La matriz de correlación (Figura 1) revela que Y tiene una correlación de 0.999 con el Equipo 1, mientras que Z tiene 0.987 con el Equipo 2. Esto sugiere que Y es el principal determinante del costo del Equipo 1 y Z del Equipo 2. La correlación entre Y y Z es de 0.85, lo que indica que comparten información parcial ($VIF \approx 3.5$).

Decisión: Dado que Y domina al Equipo 1, se evaluó si Z aporta valor adicional. Para el Equipo 2, al estar Z y Y correlacionadas, se probó si Y sola o Z sola son suficientes, o si la combinación Y+Z ofrece mejor ajuste.




Figura 1. Matriz de correlación entre variables

4.2 Series de Tiempo

La Figura 2 muestra la evolución de las 3 materias primas y los 2 equipos en el periodo 2010-2023. Se observa que X, Y y Z no presentan una tendencia clara ni estacionalidad visible. Los precios fluctúan alrededor de niveles relativamente estables, con picos ocasionales. Este comportamiento es consistente con caminatas aleatorias: no hay patron predecible a largo plazo.

Decisión: La ausencia de tendencia y estacionalidad descarta métodos como Holt-Winters o ARIMA con componentes estacionales. Se opto por métodos simples (Naive, SMA) y se confirmo la eleccion mediante backtest.




Figura 2. Series temporales mensuales

4.3 Relaciones Bivariadas

Los scatter plots (Figura 3) muestran las relaciones entre cada materia prima y cada equipo. La relacion Y-Eq1 es fuertemente lineal (puntos alineados casi perfectamente). La relacion Z-Eq2 tambien es lineal pero con mayor dispersion. Las relaciones X-Eq1 y X-Eq2 son debiles (nube de puntos dispersa).

Decisión: La linealidad observada justifica el uso de regresión lineal (OLS). X se descarta como predictor por su baja correlación visual con ambos equipos.




Figura 3. Relaciones bivariadas entre materias primas y equipos

4.4 Regresión Lineal: Combinaciones Evaluadas

Se probaron las 7 combinaciones posibles de variables utilizando regresión lineal múltiple (OLS). La Tabla 1 presenta R^2 y AIC para cada combinación.

Insights clave: (1) X sola es un predictor pobre para ambos equipos ($R^2 < 0.29$). (2) Y sola explica el 99.83% del Equipo 1 - agregar Z o X no mejora el R^2 de forma significativa. (3) Para el Equipo 2, Y sola alcanza $R^2=0.85$, Z sola $R^2=0.97$, pero Y+Z juntos llegan a $R^2=0.998$. (4) X+Y+Z da $R^2=0.9997$ pero con 3 variables, lo cual es sobregjuste para solo 164 observaciones.

Decisión: Se selecciona Y para Eq1 ($R^2=0.998$, 1 variable) y Y+Z para Eq2 ($R^2=0.998$, 2 variables). Agregar X no justifica la complejidad adicional (mejora marginal de $R^2 < 0.002$).

Variables	R2 Eq1	AIC Eq1	R2 Eq2	AIC Eq2
-----------	--------	---------	--------	---------

X	0.2799	1966	0.2861	2095
Y	0.9983	975	0.8494	1840
Z	0.7310	1804	0.9749	1546
X+Y	0.9997	665	0.8573	1833
X+Z	0.7497	1794	0.9800	1511
Y+Z	0.9983	975	0.9979	1142
X+Y+Z	0.9997	667	0.9997	795

Seleccionados: Y (Eq1), Y+Z (Eq2) - mejor R2 con menos variables.

4.5 Modelos Seleccionados

Los modelos finales se presentan en la Tabla 2. El MAE (Error Absoluto Medio) se eligió sobre el RMSE porque expresa el error en las mismas unidades que la variable objetivo (dolares): "el modelo se equivoca en promedio por \$3.83 (Eq1) o \$6.38 (Eq2)". El RMSE penaliza errores grandes al elevarlos al cuadrado, lo cual es menos apropiado para estimar un presupuesto típico donde interesa el error promedio, no el peor caso.

Insight: El sigma (desviación estándar de residuales) de \$4.69 (Eq1) y \$7.74 (Eq2) indica que el 95% de las predicciones caen dentro de $\pm \$9.19$ y $\pm \$15.17$ respectivamente, lo cual es un nivel de precisión aceptable para planificación financiera.

Eq	Var	Ecuacion	R2	MAE	σ
1	Y	Eq1 = $0.8182 \cdot Y + 5.49$	0.998	\$3.83	\$4.69
2	Y+Z	Eq2 = $0.3551 \cdot Y + 0.3368 \cdot Z + 6.49$	0.998	\$6.38	\$7.74

Nota: MAE se eligió sobre RMSE por ser directamente interpretable en dolares.

4.6 Validacion

La validacion out-of-sample (Tabla 3) entrena con datos hasta 2021 y prueba con los ultimos 24 meses (2021-2023). Los resultados muestran que ambos modelos generalizan correctamente: la diferencia entre R^2 de entrenamiento y prueba es menor a 0.004, lo que indica que no hay sobregjuste. El test de Durbin-Watson ($DW \approx 2.0$) confirma que los residuales no tienen autocorrelacion significativa, y el test de Breusch-Pagan ($p > 0.05$) no detecta heteroscedasticidad.

Insight: La estabilidad de los modelos sugiere que la relacion entre materias primas y equipos se ha mantenido relativamente constante en los ultimos 13 anos. Esto respalda la confianza en proyecciones futuras a corto plazo.

Modelo	Train R2	Test R2 (24m)	Test MAE
Eq1 ~ Y	0.993	0.990	\$8.76
Eq2 ~ Y+Z	0.985	0.986	\$17.23

$DW \sim 2.0$, BP $p > 0.05$. Modelos estables.




Figura 4. Residuales y QQ-plots

5. Proyección de Costos

Metodología

Naive (ultimo valor conocido). Costo diario promedio x 22 dias = presupuesto mensual. IC = $1.96 \times \sigma \times \sqrt{h}$.

Tabla de Proyección

Horizonte	Eq1/mes	IC 95%	Eq2/mes	IC 95%
1 mes	\$10,117	+/- \$9.19	\$20,356	+/- \$15.17
3 meses*	\$30,351	+/- \$15.92	\$61,068	+/- \$26.28
6 meses*	\$60,702	+/- \$22.52	\$122,136	+/- \$37.17

* Ilustrativos. IC crece con $\sqrt{h}$, valor puntual constante.




Figura 5. Proyección mensual con IC

Backtest: Comparacion de Métodos de Pronostico

Se compararon 3 métodos de pronostico (Naive, SMA(3), SMA(6)) mediante backtest con rolling origin: para cada mes t , se predice t usando solo datos hasta $t-1$. La metrica es MAE (dolares).

Insight: Naive obtiene el menor error en las 3 materias primas (X, Y, Z). Esto es consistente con la naturaleza de caminata aleatoria de las series, confirmada por el test ADF. En una caminata aleatoria, la mejor predicción del valor futuro es el valor actual, porque no hay informacion adicional en el historial que permita anticipar la direccion del cambio.

Decisión: Se selecciona Naive como método de pronostico. Aunque metodologicamente simple, es la opción estadisticamente correcta. SMA(3) y SMA(6) introducen rezago que aumenta el error en lugar de reducirlo.

MP	Naive	SMA(3)	SMA(6)
X	\$4.48	\$6.19	\$7.88
Y	\$24.28	\$38.27	\$49.50
Z	\$78.13	\$111.09	\$148.74

Naive gana en 3/3 materias primas. Consistente con caminata aleatoria.

6. Futuros Ajustes

1. Inferencia en tiempo real: API REST con Y/Z actualizados.
2. Reentrenamiento: Cada 6-12 meses.
3. Automatizacion: Lambda + EventBridge mensual.
4. HTTPS: nginx + Let's Encrypt en EC2.
5. Mas variables: Logisticas, cambiarias.
6. Infraestructura: Escalar si el volumen lo justifica.

7. Apreciaciones

El caso plantea un problema realista. Las ecuaciones finales y el método de pronostico se determinaron exclusivamente mediante análisis de datos (7 combinaciones, backtest, ADF).

Arquitectura minimalista en AWS: EC2 + Bedrock + S3 + Lambda, sin sobreingeniería (sin CloudFront/ALB/SageMaker/Glue/Redshift). El agente se desplego en <http://54.87.139.107:8501> combinando el análisis con búsqueda web externa.